

Estructura por capas de un video

Cómo se arma cada video del proyecto, de la voz al máster: qué capa aporta qué, quién la produce, en qué orden y por qué en ese orden. Escrito el 9 de septiembre de 2026 sobre cinco videos hechos de punta a punta (78 SUR, CONTRAMANO, EL DRON DEL VOLCÁN, EL LOCO DEL CARBÓN y la réplica de @jcfdlw).

8 MÁSTER + control montaje.mezclar · loudnorm -14 LUFS · QC lado a lado	MP4 final
7 TEXTO EN PANTALLA overlay en post · nunca pedido al generador	títulos, cifras
6 SUBTÍTULOS QUEMADOS SRT con los tiempos medidos de la voz · escala ASS	frase por frase
5 AUDIO: voz · música · ambiente ElevenLabs (Kate) · ElevenLabs Music · el audio de H3	3 pistas con ducking
4 CORTE montaje.recortar_y_concatenar · ventanas `usa`	corte.mp4
3 CLIPS DE VIDEO MiniMax H3 en Vast (4×5090) · 5,17 s por clip · reuso `clip_de`	un clip por encuadre
2 IMÁGENES: madre + primeros fotogramas nano banana Flash · hojas de modelo, locaciones, un dibujo por plano	PNG revisados a mano
1 GUION + ESTRUCTURA regla 40: la voz primero · ley de tramos · proyecto.json	planos y líneas de voz

Se lee de abajo hacia arriba: cada capa sólo puede existir cuando la de abajo está cerrada. La regla que ordena todo: **lo caro se hace último y lo que se puede revisar gratis se revisa antes**. Un dibujo mal encuadrado se ve en un PNG que costó 4 centavos; el mismo error visto en un clip costó 4 minutos de GPU.

Capa 1 · Guion y estructura

La voz es la columna (regla 40). Se escribe primero, como historia lineal, y recién después se diseñan los planos que la ilustran. Nada visual se decide antes de tener el texto cerrado y medido.

qué	detalle
texto	una línea por plano, con diálogos en «» que la misma voz actúa por puntuación
densidad	14-16 caracteres por segundo para Kate (16,7 cps medidos). El canal de referencia corre a 22,7: no se alcanza sin acelerar
estructura	la ley por tramos (estructuras/*.json): short-23 (3/8/12), short-60 (8 tramos), short-90, recap-240, largo. Fija cortes mín/máx, texto en pantalla exigido e interrupciones de patrón
proyecto.json	declarativo: estilo, personajes con hoja, locaciones, planos (ve · mueve · audio · corta · tipo · loc) y líneas de voz con su tiempo
validación	construir avisa todo lo que se aparta de la ley: corte fuera de rango, tramo sin planos, salto de eje, línea de voz que no entra. Se corrige acá, con la GPU apagada

Ritmo de corte, medido. Las dos referencias que analizamos cortan cada 2,3 s; nuestros videos propios cortan a 5,0-5,7 s. Cortar como ellos cuesta el doble de GPU porque H3 no baja de 5,17 s por clip (ver capa 3). La decisión es de plata y se toma acá, en la estructura, no en el montaje.

Capa 2 · Imágenes

Dos niveles de imagen, en este orden. Las **madre** fijan identidad; los **primeros fotogramas** fijan cada encuadre. Todo con gemini-2.5-flash-image (~\$0,04 y ~10 s por imagen; el Pro cuesta 3,4× y no hace falta para un fotograma que después re-dibuja H3).

nivel	qué es	para qué sirve
hoja de modelo	un personaje de cuerpo entero, fondo neutro, luz pareja, vestuario descripto	referencia de identidad para todos los planos donde aparece. La cara la sostiene la hoja; la ropa la sostiene el texto del prompt
locación	el lugar sin gente, plano general	referencia de fondo, paleta y luz
primer fotograma	un dibujo por plano (o por encuadre, si se reusa), con las madre como referencias	es lo que recibe H3 como punto de partida: el clip continúa desde esta imagen. Encuadre, quiénes, qué pasa

Control obligatorio: se miran todos los PNG antes de empaquetar. En la réplica se rehicieron 13 de 79 y los fallos eran tres patrones, no azar: el detalle que se abre y muestra la cara que había que recortar; la nuca en primer término que se da vuelta; la locación que se escapa (la sillita del auto en un cuarto). Cada patrón tiene un refuerzo de prompt en el generador.

Capa 3 · Clips de video

MiniMax H3 en una máquina alquilada por hora en Vast, 4× RTX 5090. Cada plano se genera desde su primer fotograma con el prompt de movimiento (*mueve*) y de sonido (*audio*). El clip sale a 768×1344, 24 fps, con su propio audio.

regla	número	de dónde sale
grilla de duración	5,17 s mínimo (124 cuadros); 5,88; 6,58...	H3 acepta 17k+5 cuadros. Fuera de la grilla adivina
largo seguro en 5090	5,17 s : 56 clips en dos corridas, cero reintentos	medido 2-3/9/2026
largo con riesgo	5,88: falla ~1 de 10 al primer intento y 3 de 33 no salieron ni en 3 pasadas	medido 3/9/2026
largo prohibido	6,58: falló 4 de 5 veces	medido 3/9/2026
costo	0,69-0,81 min de GPU por segundo generado en 5090 (0,77 típico)	COSTOS-H3 §12-13
reuso (clip_de)	un clip por encuadre, troceado entre las tomas que lo repiten. Con piso 5,17 y tomas de 2,3 s: dos tomas por clip	en el módulo desde el 3/9/2026
primer fotograma	manda: un dibujo malo da un clip malo; un dibujo bueno no garantiza un clip bueno (deriva de locación, personajes que se inventan)	QC de clips, réplica

Lo que H3 hace y lo que no. Hace lo que nace y muere dentro del plano: la acción, el foley, el ambiente. No hace nada que cruce el corte: la voz en off, la música, el texto. Y tiene dos vicios medidos: **quema subtítulos** si el estilo nombra un género que los lleva («drama corto chino»; un negativo en el prompt no lo frena), y **mete gente** donde no hay (una placa cósmica salió con la protagonista sentada delante, dos veces). Las placas gráficas se hacen como imagen fija, no se generan.

La máquina. Sólo 4×5090 (la 4090 trae 24 GB; la V100 es de 2017). Se elige por fiabilidad y costo total del trabajo, nunca por \$/h: la oferta más barata (Shanghái, \$1,60/h) quedó 20 minutos en *loading* sin arrancar. Flujo desatendido: empaquetar → alquilar --si --generar → seguir → bajar → destruir. El control visual de los clips va **antes** de destruir, en una sola pasada, porque rehacer con la instancia viva cuesta 4 minutos y sin ella cuesta otro alquiler.

Capa 4 · Corte

Cada plano declara usa = [desde, hasta]: qué tramo del clip va a la línea. Se genera de más (H3 no baja de 5,17) y se usa lo que el guion pide, con un colchón de 0,3-0,5 s al final porque el último tramo de un clip de H3 deriva. El corte se concatena sin transiciones: cortes secos, como las referencias.

La imagen sigue a la voz. Si la voz medida no entra en la ventana que el guion le dio a un plano, el corte se mueve a donde cae la frase (*linea_de_tiempo.py*): las duraciones de los planos y la colocación de la voz salen de la misma función, así que coinciden por construcción. Antes de esto la voz terminaba 5 s tarde y las últimas frases quedaban truncadas.

Capa 5 · Audio: tres pistas

pista	de dónde	cómo entra en la mezcla
voz en off	ElevenLabs v3, voz Kate. Cada línea se sintetiza en varias redacciones, se mide, y gana la que mejor calza en su ventana	arriba de todo, a su segundo exacto. Comprimir hasta 1,15× (1,30 duro); estirar hasta 1,08×. Si no entra se reescribe el texto, no se deforma el audio
música	ElevenLabs Music, una pasada de la duración exacta, descripta por función dramática	debajo, con ducking por sidechain disparado por la voz (baja cuando hay palabra)
ambiente / foley	el audio que trae cada clip de H3 (viento, agua, metal)	no se descarta: es lo que el modelo hace distinto. Se le baja mientras habla la voz. Sale clipeado (+2,68 dBFS medido) : se masteriza siempre

Máster a -14 LUFS / -1 dBTP (loudnorm), el estándar de YouTube. Sin música cuando la referencia no la tiene: el video de @jcfdlw es voz sola sobre imagen muda (45 silencios reales, piso a -62 dB), y la réplica se mezcló igual, con el audio de H3 apagado.

Capas 6 y 7 · Subtítulos y texto en pantalla

capa	qué	regla
subtítulos quemados	frase por frase, en el tercio inferior-medio, con los tiempos medidos de la voz (no los del guion)	en el género recap son parte del diseño, no un accesorio. Ojo: MarginV/FontSize del filtro van en la escala ASS 384×288, no en píxeles
texto en pantalla	la cifra que escala, el resultado del gancho, la cuenta regresiva (lo que exige cada tramo)	siempre overlay en post . Nunca pedido a la imagen ni al video: los modelos destrozan el texto y en un gancho eso es fatal

Dónde vive cada capa dentro del cuadro



768×1344 (H3) → 1080×1920 al masterizar

Las referencias de drama chino encuadran 3:4 con barras negras dentro del 9:16; nosotros generamos 9:16 a sangre. Lo que se copia es qué se ve en la toma, no las barras.

Capa 8 · Máster y control

mezclar hace corte + voz + música + ambiente + máster + subtítulos en una pasada y deja el MP4 final y una versión sin subtítulos al lado. Para un benchmark, además: el lado a lado con la referencia (misma altura, ninguno deformado) y las tomas pareadas en hojas de contacto.

El orden, y por qué

paso	qué se revisa acá	qué cuesta si se descubre después
1 guion + construir	densidad de cada línea, cortes contra la ley, tramos cubiertos	reescribir con dibujos ya pagados
2 voz --generar	duración real de cada línea (el error de estimar por densidad llega al 30 %)	un video que no calza con su voz
3 frames	encuadre, identidad, continuidad de acción, en PNG de 4 centavos	4 min de GPU por clip malo
4 empaquetar → alquilar	el ZIP con sólo las fuentes; la máquina por fiabilidad	una máquina colgada cobrando (\$0,96 el 3/9)
5 seguir → bajar	ruido por placa defectiva (detector), fallos por VRAM, taxímetro	clips de ruido puro en el máster (pasó el 31/8)
6 QC de clips → destruir	entrada / medio / salida de cada clip, una pasada con reloj	otro alquiler entero para rehacer
7 mezclar → comparar	sincronía voz-imagen, subtítulos, loudness	—

Qué cuesta cada capa (medido, 5090 a ~\$2,28/h, Flash a \$0,039)

capa	por minuto de video · corte 5,7 s	por minuto · corte 2,3 s	fijo por video
imágenes	\$0,41 (10,5 planos)	\$1,01 (26 planos) — o menos con reuso	~\$0,40 (madre)
clips de video	\$0,48 (se tira el 8 %)	\$1,05 (se tira el 56 %)	~\$0,57 (arranque, 59 GB, montaje)
voz · música	créditos del plan	créditos del plan	—
total	≈ \$0,90/min	≈ \$2,05/min	≈ \$1

Lo que no está en esa tabla y sí estuvo en las facturas: máquinas que no arrancan, clips fuera del largo seguro que fallan y se reintentan, y la máquina parada mientras se baja y se mira. En la réplica fueron \$3,71 de \$12,40 la primera vez y \$1,36 de \$4,86 la segunda. Se evitan con el orden de arriba, no con más plata.

Dónde está cada cosa

archivo	qué
ESTADO-PROYECTO.md	el mapa del proyecto; se lee primero
h3pipeline/REGLAS.md · VAST.md · COSTOS-H3.md	las 40 reglas, las 14 trampas de Vast, los números medidos
h3pipeline/estructuras/*.json	la ley de tramos por formato
referencias/FORMATOS.md	los ritmos de corte medidos; se lee antes de tocar una estructura
mis-videos/loco-carbon/RECETA.md	la receta paso a paso del formato recap
mis-videos/replica-jcfdlw/NOTAS.md	el benchmark completo: método, QC, costos, lecciones